

EVALUACIÓN TECNOLÓGICA: SISTEMA NVIDIA RTX SPARK

Infraestructura Eficiente, Rendimiento AEC y Directrices de
Ciberseguridad para Estudios de Arquitectura

¿QUÉ ES NVIDIA RTX SPARK Y PARA QUÉ SIRVE?

SUSTITUCIÓN Y COMPARATIVA DE MERCADO

IMPACTO EN LA EFICIENCIA

CIBERSEGURIDAD Y RENDIMIENTO

DIMENSIONAMIENTO E IMPLEMENTACIÓN

Conclusiones:

1. ¿QUÉ ES NVIDIA RTX SPARK Y PARA QUÉ SIRVE?

El NVIDIA RTX Spark es el nuevo sistema en chip/system on a chip (SoC) de arquitectura ARM presentado en Computex 2026.

Un SoC es tener un único chip integrado que incorpora CPU, GPU y RAM en una misma oblea. La parte buena es que al estar todo tan junto la velocidad de comunicación se dispara permitiendo ejecutar herramientas de inteligencia artificial en local de forma masiva sin tener que depender de servidores externos. Lo malo es que al ser un bloque todo en uno, se pierde la modularidad, por lo que no puedes cambiar o ampliar la RAM, lo mismo sucede con la GPU. Lo que compres el primer día es lo que tendrás durante toda la vida útil del dispositivo. Por lo que si se estropea algo no se puede reparar por piezas obligando a cambiar el chip por completo o la placa base entera, lo que complica las soluciones a estos problemas.

Está diseñado específicamente para la próxima generación de portátiles de gama alta y mini-PCs corporativos bajo el sistema operativo Windows 11 ARM64. Aunque también podría llegar a sustituir a los ordenadores de sobremesa como los conocemos.

A diferencia de los procesadores tradicionales, este SoC integra en una sola oblea/chip: una CPU 20 núcleos ARM y una GPU más o menos equivalente al rendimiento bruto de una tarjeta gráfica de escritorio de gama alta (como la RTX 5070). Su propósito principal es democratizar la computación de alto rendimiento (HPC) y la IA generativa local, alcanzando una potencia de inferencia¹ masiva de 1 petaFLOP (FP4) y haciendo así posible ejecutar modelos de lenguaje e imágenes de hasta 120 mil millones de parámetros directamente en el dispositivo cliente, eliminando la dependencia de servicios en la nube, latencias externas y costes de licencia.

¹ proceso en el que un modelo entrenado aplica lo aprendido a datos nuevos para hacer predicciones, clasificaciones o tomar decisiones en tiempo real

2. SUSTITUCIÓN Y COMPARATIVA DE MERCADO

Este SoC rompe radicalmente con el duopolio tradicional de x86 que tenían Intel y AMD al introducir soporte nativo completo para el ecosistema NVIDIA CUDA, DLSS 4, TensorRT y OptiX en entornos ARM para Windows, algo inédito en la industria de la informática personal o de consumo.

- Diferencias de la gama “Spark”: Es fundamental no confundir el nuevo RTX Spark (un SoC de consumo y profesional integrado por diversos fabricantes OEM como Microsoft, Asus, DELL, HP y Lenovo para portátiles y mini-PCs bajo Windows 11) con el producto previo, el DGX Spark. Este último es una estación de trabajo fija empaquetada en un formato de mini-PC que ejecuta exclusivamente Linux (Ubuntu), orientada estrictamente a científicos de datos y desarrollo cerrado de IA con un coste aproximado de 4700€.
- El RTX Spark en portátiles y mini-PCs compactos sustituye por completo a las torres de PC tradicionales que requieren tarjetas gráficas dedicadas de alto consumo y fuentes de alimentación masivas. Ahora un portátil de apenas 2 kg ofrece el rendimiento de una estación de trabajo dedicada.

Métrica / Feature	NVIDIA RTX Spark (Nuevo)	Apple Silicon (M4 / M5 Max)	Qualcomm Snapdragon X Elite
Arquitectura	ARM (CPU Grace + GPU Blackwell)	ARM (Diseño personalizado Apple)	ARM (Núcleos Qualcomm Oryon)
Ecosistema Gráfico	CUDA Nativo, TensorRT, OptiX, DLSS 4	Propio (Metal API / CoreML)	Adreno (DirectX, sin CUDA)
Memoria Máxima	Hasta 128 GB LPDDR5X unificada	Hasta 128 GB unificada	Hasta 64 GB unificada
Rendimiento IA (FP4)	1.000.000 TOPS (1 petaFLOP)	No compatible con FP4 nativo	~45 TOPS (NPU integrada)
Sistema Operativo	Windows 11 (Alta compatibilidad AEC)	macOS (Restringido para CAD/BIM)	Windows 11 (Gráficos muy limitados)

3. IMPACTO EN LA EFICIENCIA

Voy a tomar como ejemplo práctico a **Michelle Esterkin Reiman** ya que es una de las personas de la oficina con el ordenador más potente y que le da un uso muy exigente a este.

Su flujo de trabajo se centra en Revit, modelado en BIM complejo, pero sobre todo destaca por expresar la automatización mediante pyRevit, donde ella misma programa y crea scripts para botones customizados, además de usar herramientas avanzadas de gestión y sincronización de datos como DiRoots, JOTools y RFTools. De cara al futuro en el corto plazo, su objetivo es meter de lleno en su flujo de trabajo herramientas de diseño generativo e inteligencia artificial aplicada como Swapp, Finch, Hypar o D-to-Platform. Actualmente trabaja con una configuración tradicional, es decir x86, con la siguiente configuración:

CPU Intel Core Ultra 265K 20 NÚCLEOS/HILOS + GPU RTX 4060 8GB VRAM + RAM CORSAIR 4x32GB 4400 MHz + SSD Samsung 990 EVO

Técnicamente con esta configuración se puede producir un cuello de botella, Aunque no use intensivamente motores de render clásicos, la RTX 4060 se queda cortísima por sus 8 GB de VRAM.

Herramientas como DiRoots o RFTools procesan miles de parámetros simultáneamente, y al ejecutar scripts de pyRevit que manipulan o generan geometrías complejas en maquetas BIM pesadas, la memoria de la gráfica se satura de golpe. Lo que obliga al sistema operativo a realizar la paginación de datos hacia la memoria RAM general del sistema usando el bus PCIe.

Esto es un proceso increíblemente más lento, provocando así caídas de rendimiento brutales, congelamientos de Revit durante varios minutos o, directamente, el crasheo completo de la aplicación, haciendo perder el hilo del código o del diseño.



Mini-PCs de HP anunciados que integran RTX Spark disponibles a partir de otoño de 2026.

Si se transiciona a NVIDIA RTX SPARK:

- Punto número uno, la memoria unificada de alta velocidad (hasta 128 GB) es un pool de memoria entre la CPU y la GPU a través de un bus ultrarrápido “NVLink C2C” (300 GB/s), los scripts de pyRevit y las herramientas de extracción de datos (como JOTools o DiRoots) pueden leer y modificar bases de datos de maquetas gigantescas de forma coherente y en tiempo real. No habrá penalización por copia o escritura de datos entre componentes, terminando con los cuelgues del software al procesar modelos BIM masivos.
- Punto número dos, la 5070 ofrece mucha más potencia que la 4060 y a esto se suma su comunicación directa con el resto del sistema. Para Michelle esto es un cambio, los scripts complejos que ella misma programa y que antes tardaban en procesar reglas lógicas complejas se ejecutarán en segundos. Además, es el hardware perfecto para desplegar de forma fluida y local las plataformas de IA generativa que quiere usar (Finch, Hypar, Swapp), las cuales exigen una capacidad de inferencia masiva para calcular distribuciones espaciales y automatizar planos arquitectónicos sin depender de la nube.
- Punto número tres y último, el rendimiento por parte de la eficiencia energética y térmica es muy diferencial, prácticamente pasamos de consumir alrededor de 750W a 200W. A efectos prácticos, esto da una autonomía y potencia portátil para teletrabajar directamente en local desde su equipo si lo necesita, ejecutando sus automatizaciones y herramientas de IA generativa al 100% de velocidad, sin sufrir los molestos retrasos, pérdidas de calidad o latencia que genera trabajar a través de un escritorio remoto.



*Portátiles RTX Spark anunciados
para otoño de 2026*

4. CIBERSEGURIDAD Y RENDIMIENTO

Seguridad por Hardware: Al ser arquitectura ARMv9 (arquitectura Grace), incluye protección nativa contra corrupción de memoria (tecnologías PAC y BTI), esto es clave para mitigar ataques que puedan entrar a través de plugins de Revit de terceros mal optimizados. Además, debido a su antigüedad los sistemas x86 arrastran vulnerabilidades históricas de diseño (como Spectre o Meltdown). Cosa que ARMv9 al ser más nuevo está pensado para ser mucho más seguro.

Soberanía de Datos (RGPD): Al poder correr los modelos de IA en local gracias a la potencia del chip, no se tiene que enviar planos confidenciales, maquetas o datos de clientes a servidores externos (como OpenAI). Todo se queda dentro del endpoint, cumpliendo de forma estricta con la confidencialidad y el RGPD. Todo esto si se quiere hacer claro. Además, de que los datos están almacenados en los mini-PCs sin estar en los escritorios de los trabajadores por lo que se eliminan riesgos de pérdidas de datos por un accidente.

En cuanto a rendimiento como ya se ha hablado mucho de manera más dispersa en este informe sobre potencia voy a destacar algo en lo que menos gente piensa:

Eficiencia térmica y energética: x86 (CISC) arrastra mucha herencia del pasado; para rendir necesita frecuencias altas que disparan el consumo y generan sobrecalentamiento (thermal throttling). ARM (RISC) usa instrucciones simplificadas en hardware, dando un rendimiento brutal con un consumo mínimo y sin apenas calentarse. Además, si ponemos en cuenta los SAI e incluso implementamos generadores de emergencia, pese a irse la luz todos en la oficina podrían más o menos seguir trabajando si se alimentan los mini-PCs servidor, NASH, Firewall físico (Forti) y los Tiny Clients con sus monitores, la razón es simple, realmente en consumo no tienen comparación ya que necesitan tan poca energía para funcionar a pleno rendimiento que solo habría que sumar el gasto energético de todo esto y ya tendrías independencia de la red eléctrica en caso de emergencia como si ese día se va la luz en toda la calle por obras, no se perdería el día de trabajo.

5. DIMENSIONAMIENTO E IMPLEMENTACIÓN

Como estos equipos tienen un coste bastante elevado y aún tardarán un poco en llegar al mercado, lo que podríamos hacer idealmente es comprar inicialmente un único portátil o mini-PC con este SoC para usarlo como equipo compartido para proyectos importantes y que así se vaya probando a ver si cumple

De todas formas vamos a hacer un ejemplo para un supuesto equipo de alrededor de 20 arquitectos como podría ser el estudio de Madrid, no es necesario ni eficiente adquirir 20 licencias independientes de estaciones fijas de alto coste. Se podría solucionar con una infraestructura híbrida si se optimiza con cabeza:

“X” cantidad de portátiles RTX Spark de 128 GB asignados a los arquitectos principales y diseñadores activos que requieren modelar localmente, renderizar en tiempo real y además tener movilidad para viajar a obras o realizar presentaciones fotorrealistas e inmersivas incluso pudiendo ejecutar VR in situ con clientes.

4 o 8 mini-PC RTX Spark también de 128 GB instalados de forma centralizada en el rack local del estudio, para concretar actuarían como nodos de servicio compartido de alta densidad energética para todo el equipo, aprovechando su ancho de banda de red ya que implementan puertos de alta velocidad de 10 GbE o USB4/Thunderbolt 5 y la inmensa cantidad de memoria unificada.

Su implementados de la siguiente manera:

- Escritorios Virtuales (VDI) de un muy Alto Rendimiento: Los mini-PCs se configuraran bajo un hipervisor tipo 1 adaptado a ARM64 (ej: Microsoft Hyper-V Server) o Windows Server. Aprovechando el acceso a la memoria de la GPU, se implementará la segmentación de recursos gráficos y cómputo como se quiera. Cada mini-PC puede dar servicio a 4 usuarios concurrentes para tareas de CAD, Revit, Rhino, etc asignando dinámicamente a cada sesión RPD acelerada, o protocolos de ultra-baja latencia como Moonlight/Sunshine, un pool de 32 GB de memoria unificada y 1536 núcleos CUDA.
- ¿Qué ponemos en cada puesto de trabajo? En las mesas se aprovechan los ordenadores viejos que ya tenemos o se compran Thin Clients (clientes ligeros muy baratos, de unos 100 o 150€). El arquitecto conecta ahí su monitor, teclado y ratón, y se conecta al Mini-PC del rack directamente por el cable Ethernet de la oficina que tenemos diseñado, disfrutando de una conexión a ras de cable, sin latencia y a máxima velocidad (siempre y cuando los cables ethernet soportan la capacidad de 10 GbE que tienen estos mini-PCs).
- Acceso Remoto: Para cuando tengan que teletrabajar o ir a la obra, usamos el Fortinet que ya tenemos implementado en la oficina. Se configuran los accesos en el Fortinet mediante túneles seguros (SSL-VPN / IPsec con FortiClient o lo que ya tengamos) y se activa la autenticación multifactor si se quiere.

Nota Importante: Debido a que el entorno se ejecuta sobre Windows 11 en ARM, las herramientas con soporte nativo (CUDA nativo, motores de renderizado directo) funcionarán al 100% desde el primer día. Las aplicaciones heredadas x86 que no cuenten con versión ARM nativa se ejecutarán bajo la capa de emulación Prism de Microsoft, introduciendo una penalización de rendimiento estimada de entre el 15% y el 25%. Es indispensable realizar una auditoría previa del catálogo de aplicaciones y plugins antes de nada. Y aun así sigue siendo más potente que lo que hay disponible en oficina

Conclusiones:

Es una tecnología innovadora y que va a suponer un cambio en el largo plazo cuando los precios bajen y democratizen un poco el acceso a estos productos.

Ahora mismo para una implementación yo creo que pueden estar un poco verdes si se quieren dividir en VMs para los trabajos más pesados, pero para los trabajadores que solamente hacen planos 2D o trabajos muy ligeros puede suponer una gran mejora además de el factor de quitar 4 ordenadores y solo usar uno entre 4.

Lo que realmente hay que hacer es una prueba cuando salgan con uno y vemos cómo se desempeña.

Eso sí, como menciono en la nota importante de arriba, que las aplicaciones de Revit y CAD, por ejemplo, aún no están implementadas oficialmente en los sistemas ARM así que todo se tendría que usar mediante traductor de código de Microsoft que es algo nativo de Windows 11 ARM y va bien, pero simplemente que estas aplicaciones no aprovechan del todo las capacidades de esta máquina hasta que no hagan versiones nativas, solo hay que ver el salto que hubo cuando APPLE sacó los ARM M1 y las diferencias que hay entre usar versiones de x86 traducidas con APPLE ROSETTA y las nativas de ARM APPLE SILICON, son la noche y el día...